Рубежный контроль №1

Методы машинного обучения в АСОИУ. Вариант №4

Задачи варианта:

- **Задача №4.** Для набора данных провести кодирование одного (произвольного) категориального признака с использованием метода *label encoding*.
- **Задача №24.** Для набора данных для одного (произвольного) числового признака провести обнаружение и удаление выбросов на основе 5% и 95% квантилей.

Используемый набор данных: `penguins` (Palmer Archipelago Penguins) из библиотеки `seaborn`.

Датасет содержит измерения трёх видов пингвинов с островов архипелага Палмер (Антарктида). В нём присутствуют как категориальные признаки (`species`, `island`, `sex`), так и числовые (`bill_length_mm`, `bill_depth_mm`, `flipper_length_mm`, `body_mass_g`), что соответствует условиям обеих задач.

Подключение библиотек и загрузка данных

```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.preprocessing import LabelEncoder

sns.set_theme(style='whitegrid')
pd.set_option('display.max_columns', None)
```

```
data = sns.load_dataset('penguins')
print('Размер датасета:', data.shape)
data.head()
```

```
Размер датасета: (344, 7)
```

	species	island	bill_length_mm	bill_depth_mm	flipper_length_mm	body_mass_g	sex
0	Adelie	Torgersen	39.1	18.7	181.0	3750.0	Male
1	Adelie	Torgersen	39.5	17.4	186.0	3800.0	Female
2	Adelie	Torgersen	40.3	18.0	195.0	3250.0	Female
3	Adelie	Torgersen	NaN	NaN	NaN	NaN	NaN
4	Adelie	Torgersen	36.7	19.3	193.0	3450.0	Female

```
data.info()
```

```
<class 'pandas.DataFrame'>
RangeIndex: 344 entries, 0 to 343
Data columns (total 7 columns):
 #   Column             Non-Null Count  Dtype
---  ------             --------------  -----
 0   species            344 non-null    str
 1   island             344 non-null    str
 2   bill_length_mm     342 non-null    float64
 3   bill_depth_mm      342 non-null    float64
 4   flipper_length_mm  342 non-null    float64
 5   body_mass_g        342 non-null    float64
 6   sex                333 non-null    str
dtypes: float64(4), str(3)
memory usage: 18.9 KB
```

Задача №4. Label Encoding категориального признака

Постановка: провести кодирование одного произвольного категориального признака методом *label encoding*.

Идея метода. Каждому уникальному значению категориального признака ставится в соответствие целое число от 0 до $n-1$, где n — число уникальных категорий. В отличие от one-hot encoding, размерность пространства признаков не растёт, но между категориями появляется искусственный порядок, что нужно учитывать при выборе моделей.

Выбранный признак: `species` — вид пингвина (3 категории: *Adelie*, *Chinstrap*, *Gentoo*).

```
feature = 'species'
print('Уникальные значения признака:', data[feature].unique())
print('\nЧастоты:')
print(data[feature].value_counts())
```

```
Уникальные значения признака: <StringArray>
['Adelie', 'Chinstrap', 'Gentoo']
Length: 3, dtype: str

Частоты:
species
Adelie       152
Gentoo       124
Chinstrap     68
Name: count, dtype: int64
```

Применение `LabelEncoder` из `sklearn.preprocessing`

```
le = LabelEncoder()
data['species_le'] = le.fit_transform(data[feature])

print('Соответствие категория → код:')
for code, category in enumerate(le.classes_):
    print(f'  {category!r:>12} -> {code}')
```

```
Соответствие категория → код:
      'Adelie' -> 0
   'Chinstrap' -> 1
      'Gentoo' -> 2
```

```
data[[feature, 'species_le']].head(10)
```

	species	species_le
0	Adelie	0
1	Adelie	0
2	Adelie	0
3	Adelie	0
4	Adelie	0
5	Adelie	0
6	Adelie	0
7	Adelie	0
8	Adelie	0
9	Adelie	0

Проверка обратного преобразования

Метод `inverse_transform` восстанавливает исходные категориальные значения по их числовым кодам — это удобно при интерпретации результатов модели.

```
sample_codes = data['species_le'].head(5).values
print('Коды:           ', sample_codes)
print('Восстановленные:', le.inverse_transform(sample_codes))
```

```
Коды:            [0 0 0 0 0]
Восстановленные: ['Adelie' 'Adelie' 'Adelie' 'Adelie' 'Adelie']
```

Визуализация результата кодирования

```
fig, axes = plt.subplots(1, 2, figsize=(12, 4))

sns.countplot(x=feature, data=data, ax=axes[0], order=le.classes_)
axes[0].set_title('До кодирования (категории)')

sns.countplot(x='species_le', data=data, ax=axes[1])
axes[1].set_title('После label encoding (числовые коды)')

plt.tight_layout()
plt.show()
```

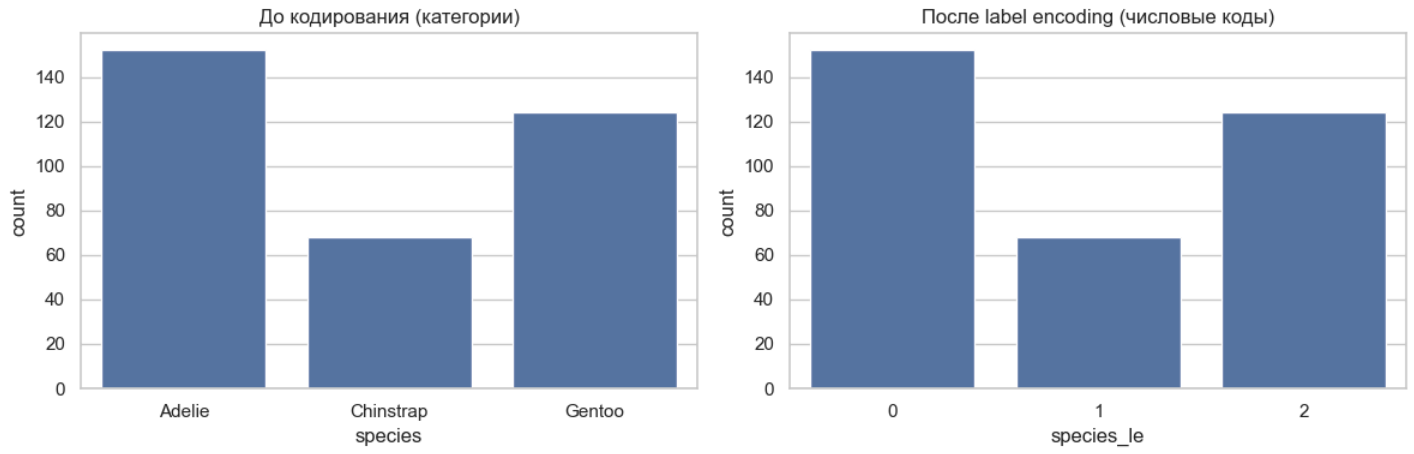

Вывод по задаче №4. Признак `species` успешно закодирован методом *label encoding*: три категории (*Adelie*, *Chinstrap*, *Gentoo*) преобразованы в целочисленные значения $\{0, 1, 2\}$. Распределение количества наблюдений по классам сохранилось (что и ожидается — кодирование не изменяет состав данных, только их представление).

Задача №24. Обнаружение и удаление выбросов по 5% и 95% квантилям

Постановка: для одного произвольного числового признака провести обнаружение и удаление выбросов на основе 5% и 95% квантилей.

Идея метода. Вычисляются квантили $Q_{0.05}$ и $Q_{0.95}$ — границы, между которыми лежит центральные 90% значений признака. Все наблюдения, у которых значение признака меньше $Q_{0.05}$ или больше $Q_{0.95}$, считаются выбросами и удаляются. Это простой и устойчивый подход, не требующий предположений о форме распределения (в отличие от метода $\mu \pm 3\sigma$).

Выбранный признак: `body_mass_g` — масса тела пингвина в граммах.

```
num_feature = 'body_mass_g'

df = data.dropna(subset=[num_feature]).copy()
print(f'Размер выборки до обработки: {len(df)}')
df[num_feature].describe()
```

```
Размер выборки до обработки: 342
count     342.000000
mean     4201.754386
std       801.954536
min      2700.000000
25%      3550.000000
50%      4050.000000
75%      4750.000000
max      6300.000000
Name: body_mass_g, dtype: float64
```

Визуализация исходного распределения

```
fig, axes = plt.subplots(1, 2, figsize=(12, 4))

sns.histplot(df[num_feature], kde=True, ax=axes[0], bins=30)
axes[0].set_title(f'Гистограмма {num_feature} (до)')

sns.boxplot(x=df[num_feature], ax=axes[1])
axes[1].set_title(f'Ящик с усами {num_feature} (до)')

plt.tight_layout()
plt.show()
```

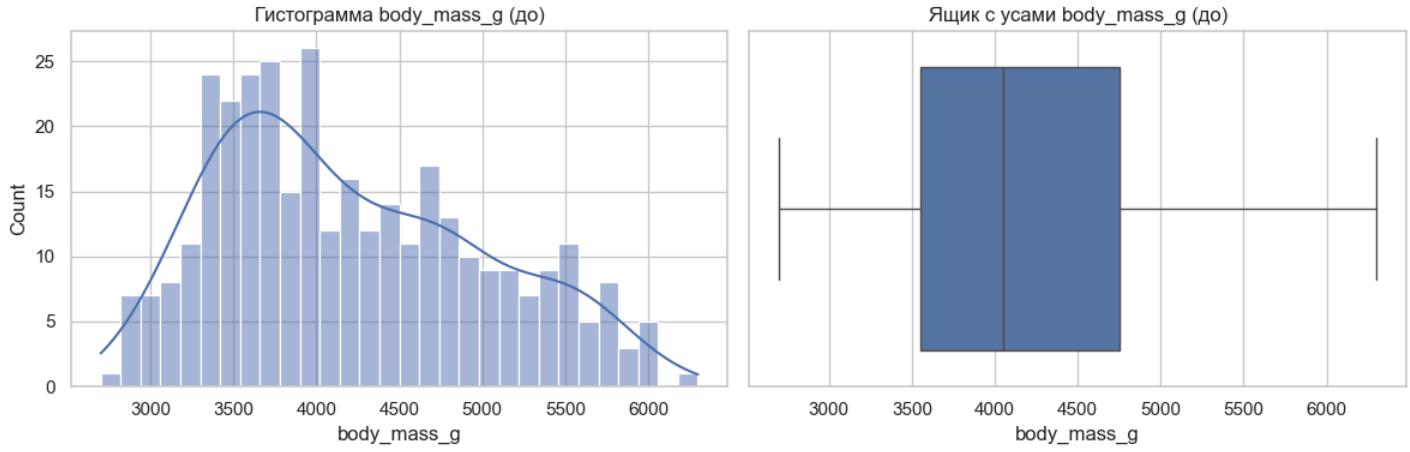

Расчёт 5% и 95% квантилей

```
q_low = df[num_feature].quantile(0.05)
q_high = df[num_feature].quantile(0.95)

print(f'5%  квантиль (нижняя граница): {q_low:.2f}')
print(f'95% квантиль (верхняя граница): {q_high:.2f}')
```

```
5%  квантиль (нижняя граница): 3150.00
95% квантиль (верхняя граница): 5650.00
```

Идентификация выбросов

```
outliers_mask = (df[num_feature] < q_low) | (df[num_feature] > q_high)
outliers = df[outliers_mask]

print(f'Найдено выбросов: {len(outliers)} ({len(outliers) / len(df) * 100:.2f}% от выборки)')
print('\nПримеры выбросов:')
outliers[[num_feature, 'species', 'island', 'sex']].head(10)
```

```
Найдено выбросов: 34 (9.94% от выборки)

Примеры выбросов:
```

	body_mass_g	species	island	sex
42	3100.0	Adelie	Dream	Female
44	3000.0	Adelie	Dream	Female
47	2975.0	Adelie	Dream	NaN
54	2900.0	Adelie	Biscoe	Female
58	2850.0	Adelie	Biscoe	Female
64	2850.0	Adelie	Biscoe	Female
68	3050.0	Adelie	Torgersen	Female
98	2900.0	Adelie	Dream	Female
102	3075.0	Adelie	Biscoe	Female
104	2925.0	Adelie	Biscoe	Female

Удаление выбросов

```
df_clean = df[~outliers_mask].copy()

print(f'Размер выборки до удаления выбросов:    {len(df)}')
print(f'Размер выборки после удаления выбросов: {len(df_clean)}')
print(f'Удалено объектов: {len(df) - len(df_clean)}')
```

```
Размер выборки до удаления выбросов:    342
Размер выборки после удаления выбросов: 308
Удалено объектов: 34
```

```
pd.concat(
    [df[num_feature].describe(), df_clean[num_feature].describe()],
    axis=1,
    keys=['Исходные', 'После очистки']
)
```

	Исходные	После очистки
count	342.000000	308.000000
mean	4201.754386	4178.814935
std	801.954536	688.117250
min	2700.000000	3150.000000
25%	3550.000000	3600.000000
50%	4050.000000	4050.000000
75%	4750.000000	4700.000000
max	6300.000000	5650.000000

Сравнение распределений до и после очистки

```
fig, axes = plt.subplots(2, 2, figsize=(12, 8))

sns.histplot(df[num_feature], kde=True, ax=axes[0, 0], bins=30, color='steelblue')
axes[0, 0].axvline(q_low, color='red', linestyle='--', label=f'5%: {q_low:.0f}')
axes[0, 0].axvline(q_high, color='red', linestyle='--', label=f'95%: {q_high:.0f}')
axes[0, 0].legend()
axes[0, 0].set_title('Гистограмма ДО очистки')

sns.histplot(df_clean[num_feature], kde=True, ax=axes[0, 1], bins=30, color='seagreen')
axes[0, 1].set_title('Гистограмма ПОСЛЕ очистки')

sns.boxplot(x=df[num_feature], ax=axes[1, 0], color='steelblue')
axes[1, 0].set_title('Boxplot ДО очистки')

sns.boxplot(x=df_clean[num_feature], ax=axes[1, 1], color='seagreen')
axes[1, 1].set_title('Boxplot ПОСЛЕ очистки')

plt.tight_layout()
plt.show()
```

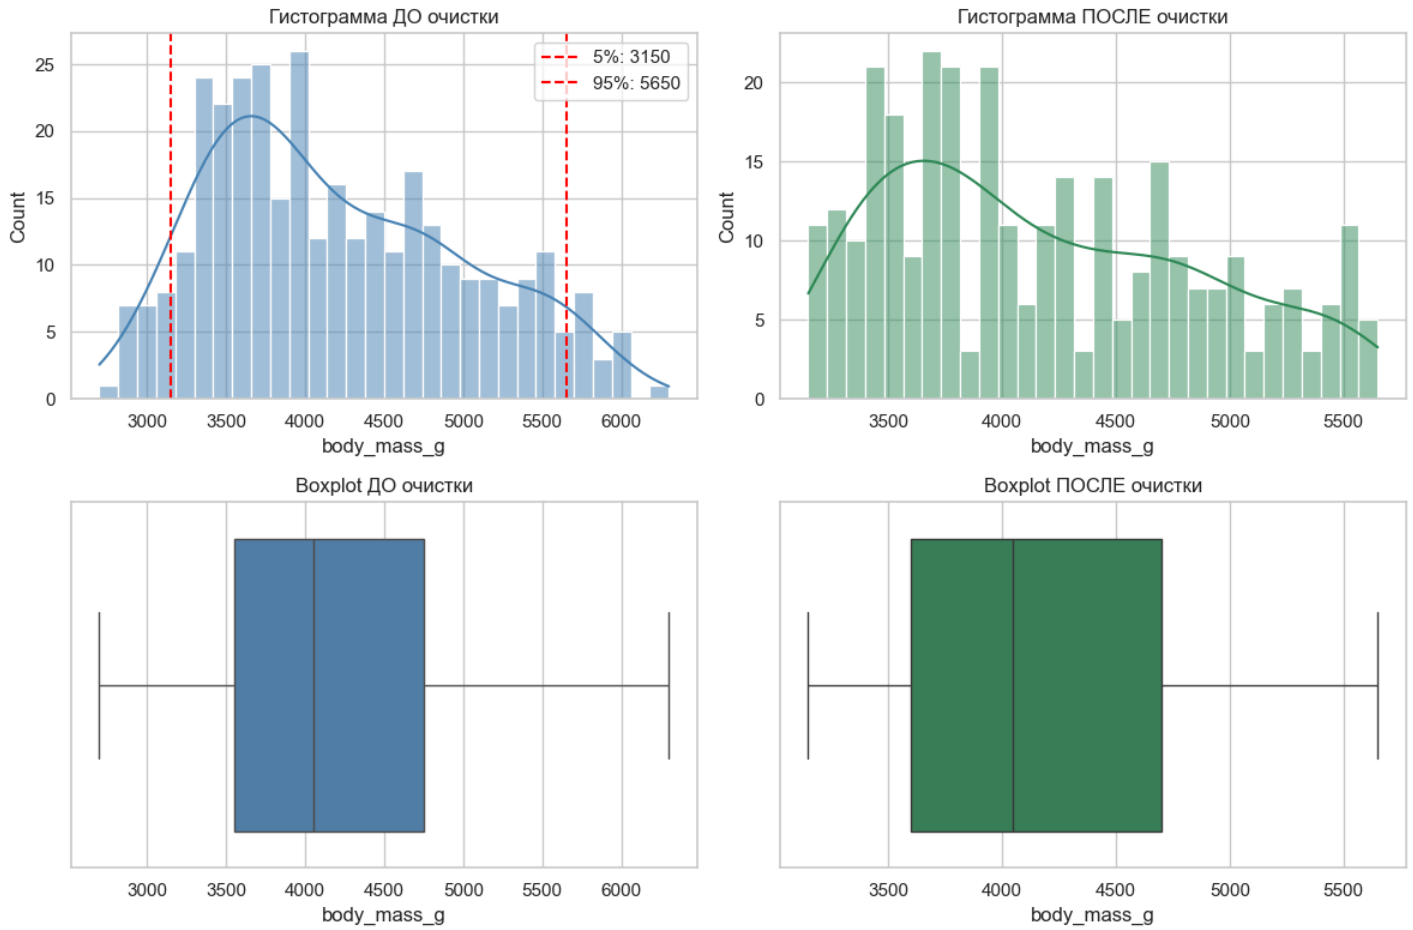

Вывод по задаче №24. На основе 5% и 95% квантилей признака `body_mass_g` определены границы $[Q_{0.05}, Q_{0.95}]$, за пределами которых наблюдения считаются выбросами. Эти объекты удалены из выборки. На графиках видно, что после очистки распределение признака стало компактнее, на boxplot исчезли точки за границами усов, а описательные статистики (`min`, `max`,

стандартное отклонение) изменились в ожидаемую сторону. Отметим, что метод по построению удаляет около 10% данных (по 5% с каждого конца), поэтому применять его следует обдуманно — особенно когда «выбросы» могут нести содержательную информацию.